

**ИНФОРМАЦИОННЫЕ ОСНОВЫ ВЫДЕЛЕНИЯ
АББРЕВИАТУР И
ИХ РАСШИФРОВКИ В ТЕКСТЕ НА РУССКОМ ЯЗЫКЕ**

**Ивнов И.И., Петров П.П., Васильев В.В.
ФГКВОУВО «Академия ФСО России»,
Россия, Орёл**

Аннотация. Данная работа описывает теоретические основы автоматизированного выделения аббревиатур и определения их расшифровок в текстах на русском языке. Изложено текущее состояние предметной области, рассмотрены существующие программные средства автоматизированного составления списка аббревиатур и их расшифровок. Приводится классификация аббревиатур по структурно-информационным признакам. Предложенная классификация подходит для создания алгоритмов автоматизированного выделения аббревиатур. Разработан подход к определению расшифровки аббревиатур без их непосредственного введения в текст.

Ключевые слова: аббревиатура, расшифровка аббревиатуры, выделение аббревиатур, классификация аббревиатур.

1. Вводные положения

Развитие аббревиации и использование сокращенных лексических единиц – общая тенденция для многих алфавитных языков. Так, аббревиатуры широко используются не только в специализированных областях знания, но и в повседневной коммуникации [1].

Введём ряд определений. Под *аббревиатурой* будем понимать слово, образованное сокращением слова или словосочетания, читаемое по названию начальных букв или по начальным и крайним (общепринятые аббревиатуры) звукам слов, входящих в него. Под *расшифровкой* или *полной формой аббревиатуры* будем понимать последовательность слов, от которых образована аббревиатура. *Введением аббревиатуры* в текст является определенная последовательность аббревиатуры и её расшифровки в одном предложении текста. *Аббревиатурой без расшифровки* является аббревиатура, не имеющая расшифровки в предложении, где она расположена. *Под выделением аббревиатуры (расшифровки)* будем понимать получение структурной информации об аббревиатуре (расшифровке) для её дальнейшего использования.

Употребление аббревиатур – специфическая особенность научно - технических текстов, в которых аббревиатурам принадлежит большая доля информационной нагрузки [2]. В текстах художественного стиля практически отсутствуют аббревиатуры в виду отсутствия ёмких терминов, которые необходимо сокращать.

В научно-технических текстах на русском языке из различных областей знаний используются разнообразные аббревиатуры, что затрудняет возможность интуитивной расшифровки аббревиатуры человеком, читающим текст. При отсутствии *списка аббревиатур* и соответствующих им *рас-*




Рис. 1: – Типы текстов с аббревиатурами (разработано авторами)

шифровок (САиР) для текста возникают трудности с интерпретацией аббревиатур. При этом в большинстве текстов достаточно информации для того, чтобы по определенным признакам восстановить или создать данный список. Это утверждение положено в основу данной статьи. Для отдельных текстов информации, содержащейся внутри них, может быть недостаточно, чтобы восстановить САиР. Тогда следует прибегать к анализу других текстов схожей тематики.

кого класса задач обработки текстов. Здесь можно упомянуть межъязыковые преобразования текстов, в том числе – конверсию графических систем письма [3], расчет характеристик сложности текста [4], автоматизированное извлечение ключевых слов [5], рерайтинг [6] и квалиметрический анализ текста [7]. Во всех перечисленных задачах необходимо произвести предварительное выделение аббревиатур и их расшифровок (ВАиР) из текста.

Исходя из результатов исследования тексты на русском и английском языках можно разделить на три типа (рисунок 1):

1. Тексты, в которых присутствует САиР, *введения аббревиатур и аббревиатуры без расшифровок*.
2. Тексты, в которых присутствуют *введения аббревиатур и аббревиатуры без расшифровок* (введённые ранее).
3. Тексты, в которых присутствуют только *аббревиатуры без расшифровок* (ранее не были введены).

Предполагается, что результаты исследования будут актуальны и для других алфавитных языков. Также установлено, что тексты научно-технического стиля более насыщены аббревиатурами, чем тексты аналогичного объёма художественного стиля.

2. Состояние предметной области

В работах [8-10] представляются различные классификации аббревиатур, но не предложено решений по выделению их из текстов.

В работе [11] предложено решение для нахождения полного названия журнала по его аббревиатуре. Неизвестная аббревиатура, указанная пользователем, приводилась в формат регулярного выражения, которое предполагало возможный набор слов, начинающийся с указанных букв. Специфическая реализация полученного решения не позволяет использовать его для определения полных форм аббревиатур из других предметных областей.

В работах [12, 13] на основании определения частот встречаемости соседних слов определяется мера их связности, что позволяет предложить

вероятные полные формы аббревиатур. Достоинством такого метода является его универсальность, недостатком – высокая трудоёмкость. Материалы данных работ использовались при разработке модели процесса выделения аббревиатур. В работах [14, 15] предложено исходный текст представлять в виде совокупности тем, которые образуются множеством входящих в них с разной вероятностью слов. Найденная схожесть частей текста используется как представление полной формы аббревиатуры. Данный подход предлагает множество решений с близкими вероятностями, что предусматривает дополнительную работу для пользователя на стадии отбора расшифровки интересующей аббревиатуры.

Существуют программы для ЭВМ, зарегистрированные в Федеральной службе по интеллектуальной собственности (Роспатент), обладающие возможностью выявления САиР. Так, программа [16] реализует функцию автоматизированного формирования перечня аббревиатур, решает задачу формирования единой базы терминов (аббревиатур) и их определений (расшифровок). Программа [17] предназначена для автоматизированного извлечения терминологических структур из монографии заданной предметной области. Одной из основных функций программы является извлечение терминов, в частности, расшифровка аббревиатур.

3. Классификация аббревиатур

Формирование классификации аббревиатур осложнено особенностями их структуры, большой вариативностью, множеством различных способов аббревиации, а также взаимодействием аббревиации с другими способами словообразования. Исследователи [10, 18, 19] сходятся во мнении, что аббревиатуры можно подразделять на инициальные, сложносокращённые и общепринятые. В первом случае аббревиатура составляется из первых букв её расшифровки. Во втором случае в аббревиатуру включены не только первые, но и другие буквы сокращаемых слов [20]. В третьем случае аббревиатуры имеют уникальное представление в тексте и единственную расшифровку. Общепринятые аббревиатуры, как правило, интуитивно понятны и употребляются перед определёнными структурами в тексте.

Для решения задачи автоматизированного ВАиР из текста введём классификацию по структурно-информационным признакам, а также приведём в первом приближении их распространенность, изученную на материале ста случайно отобранных статей с ресурса Cyberleninka.ru. Аббревиатуры разделяются на три класса: инициальные, общепринятые и сложносокращённые. Инициальные и общепринятые аббревиатуры имеют выраженную структуру (прописные буквы, знаки препинания), которой сложносокращённые не обладают (структурный признак). При этом, общепринятые аббревиатуры имеют интуитивно понятный смысл, а инициальные требуют расшифровки в тексте (информационный признак). Сложносокращённые аббревиатуры, не имеющие в составе прописных букв (завхоз, ликбез и т.д.), рассматриваться в данной статье не будут. Инициальные аббревиатуры разделены на пять типов, каждый из которых отличается по структурным признакам (рисунок 2).

Для создания программного средства ВАиР необходимо учитывать




Рис. 2: Классификация аббревиатур по структурно- информационным признакам (разработано авторами)

особенности каждого класса рассматриваемых аббревиатур.

Особенности инициальных и общепринятых аббревиатур:

1. (тип А, 53%) Инициальная аббревиатура, в которой слова полной формы разделены только пробелами и в неё входят только первые буквы слов полной формы. Например: центр информационной безопасности (ЦИБ), Latent Dirichlet Allocation (LDA).

2. (тип В, 5%) Инициальная аббревиатура, в которой некоторые слова полной формы объединены знаком дефис или символом «косой черты». Например: оптико-тепловизионный комплекс (ОТК), read- only memory (ROM), input/output (IO).

3. (тип С, 22%) Инициальная аббревиатура с элементами сложно-сокращённых слов. При этом, аббревиатура может состоять не только из прописных букв, но первая буква полной формы должна соответствовать первой букве аббревиатуры. Количество слов в расшифровке не совпадает с количеством букв в аббревиатуре. Например: гидрометеорологическая станция (ГМС), ammonium bifluoride (ABF), Белорусский автомобильный завод (БелАЗ), временно исполняющий обязанности (ВрИО).

4. (тип D, 5%) Инициальная аббревиатура, отличная от языка документа. Например, протокол передачи файлов (FTP), временный идентификационный номер подвижного абонента (TMSI).

5. (тип E, 2%) Инициальная аббревиатура, в которой буквы аббревиатуры разделены точками, а первые буквы слов полной формы соответствуют буквам в аббревиатуре. Например: Фамилия Имя Отчество (Ф.И.О.), Петроградская сторона (П.С.).

6. Общепринятые аббревиатуры (13%), которые применяются в разных областях: адреса (г., ул., д., пр-т), звания (к-т, л-т), точные науки (см, Гц), время суток (a.m, p.m), элемент текста (P.S.) и т.п. Они не имеют полной формы в тексте и будут расшифровываться по словарю.

Для примеров были использованы аббревиатуры на русском и английском языках, но предполагается, что данная классификация актуальна и для других алфавитных языков.

3. Модель процесса выделения аббревиатур и расшифровок из текста

Процесс выделения аббревиатур и их расшифровок в общем может состоять из двух этапов.

Первый этап заключается в разделении исходного текста на предложения. Он необходим для более точного определения расшифровок аббревиатур. Разделителем предложений в тексте могут являться восклицательные и вопросительные знаки, многоточия, знаки переноса строки и точки. Однако возникает ряд проблем, связанных с тем, что точки ставятся в тексте не только в конце предложения. Чаще всего точки можно встретить в следующих конструкциях: в датах (25.10.20 г.), в адресах (ул. Ленина, д. 7), в общих аббревиатурах (т.д.), в буквенно-цифровых обозначениях (66.КП.ВРБ.00.00.00.ВО), перед номерами телефонов (тел. 89997773737), в нумерации (1.1, 1.2, ...), в составе сокращения ФИО (А.А. Иванов) и в инициальных аббревиатурах (R.I.S.K.).

Второй этап разбивается на две параллельных части: *поиск мест введения аббревиатур* и *поиск аббревиатур без расшифровок* в предложениях.

Поиск мест введения аббревиатур заключается в анализе предложения на предмет наличия аббревиатуры и соответствующей расшифровки. В случае успеха информация о расшифровке и соответствующей аббревиатуре заносится в базу данных. Одна аббревиатура вводится в тексте только один раз.

Введения аббревиатур имеют определенную структуру, которая задается формулой (таблица 1) [3]. Возможны ситуации, когда при введении аббревиатуры в скобках может присутствовать текст, который не относится ни к расшифровке, ни к аббревиатуре.

Таблица 1 – Типовые формулы введения аббревиатур

Формула введения	Примеры
расшифровка (аббревиатура)	Специальное программное обеспечение (СПО), система (С)
аббревиатура (расшифровка)	АС (автоматическая сигнализация), СО (сигнал ожидания)
расшифровка аббревиатура	Процессор преобразования матриц ППМ, двухпроцессорная система ДС
аббревиатура – расшифровка	ЯМД – язык манипулирования данными, ЯУ – язык управления
(расшифровка – аббревиатура)	(Главная машина – ГМ)

Поиск аббревиатур без расшифровок заключается в определении по определенным признакам наличия аббревиатур в предложении.

В процессе поиска могут встречаться аббревиатуры, которые ранее не были введены в текст. В связи с этим появляется необходимость поиска информации об их расшифровках по другим источникам. Для корректного сопоставления аббревиатуры и расшифровки из разных текстов, необходимо учитывать контекст аббревиатур (рисунок 3).

Так как одна аббревиатура вводится в текст, как правило, только один раз, то далее по тексту будут встречаться только аббревиатуры без



Рис. 3: – Соответствие расшифровки, аббревиатуры и контекста (разработано авторами)




Рис. 4: Принципиальная схема выделения аббревиатур и расшифровок в тексте (разработано авторами)

расшифровок, при этом каждая выделенная аббревиатура будет однозначно соответствовать введенной ранее. Далее от предложения к предложению необходимо считывать аббревиатуры и их контекст в базу данных, после чего производить сопоставление с информацией, полученной при *поиске мест введения аббревиатур*. В случае отсутствия расшифровок необходимо производить поиск по другим текстам или по словарю.

Принципиальная схема ВАиР в тексте приведена на рисунке 4.

5. Заключение

В статье рассматривается обобщенное гиперболическое уравнение запаздывающего типа с некарлемановскими сдвигами вида $U_{xx}(x, y) - U_{yy}(x, y) = H(x - \tau)[U_x(x - \tau, y) + U(x - \tau, y)]$,

в области

$$D = \{(x, y) : x > 0, y < 0\} = \int_{k=0}^{\infty} D_k$$

где

$$D_k = \{(x, y) : k\tau - y \leq x \leq (k+1)\tau + y, -\frac{\tau}{2} < y < 0\} (k = 0, 1, 2, \dots)$$

Задача К. Найди в области D решение уравнения из класса $C(\bar{D} \sim C^2(D))$, удовлетворяющее условиям

$$U(x, y)|_{y=0} = (x), x \geq 0,$$

$$U_y(x, y)|_{y=0} = v(x), x > 0,$$

где $(x), v(x)$ - заданные непрерывные достаточно гладкие функции, причем $(0 = (+\infty) = 0$.

Список литературы

1. Максименко, О.И. Новые тенденции аббревиации (на материале русского, английского и немецкого языков) // Вестник Российского университета дружбы народов. Серия: Теория языка. Семиотика. Семантика. – 2017. – Т. 8. – № 1. – С. 174-181.
2. Грязнухина, Т.А. Лингвистические проблемы автоматизации редакционно-издательских процессов / Т.А. Грязнухина, Н.П. Дарчук, Л.И. Комарова и др.; отв. ред. В.И. Перебийнос, М.Д. Феллер // колл. монография: Академия наук УССР, Институт языковедения им. А.А. Потебни. — Киев: Наукова думка, 1986. – 229 с.
3. Гращенко, Л.А. Информационные основы польско-русского межъязыкового преобразования текстов / Л.А. Гращенко, Н.Н. Пивоваров // Новые информационные технологии в автоматизированных системах. – 2016. – № 19. – С. 101-106.
4. Мизернов, И.Ю. Анализ методов оценки сложности текста / И.Ю. Мизернов, Л.А. Гращенко // Новые информационные технологии в автоматизированных системах. – 2015. – № 18. – С. 572- 581.
5. Ванюшкин, А.С. Методы и алгоритмы извлечения ключевых слов / А.С. Ванюшкин, Л.А. Гращенко // Новые информационные технологии в автоматизированных системах. – 2016. – № 19. – С. 85- 93.
6. Науменко, Д.А. Информационные основы автоматизации ререйтинга / Д.А. Науменко, Л.А. Гращенко, Г.В. Романишин // Новые информационные технологии в автоматизированных системах. – 2019. – № 22. – С. 187-191.
7. Гращенко, Л.А. Опыт автоматизированного анализа повторов в научных текстах / Л.А. Гращенко, Г.В. Романишин // Новые информационные технологии в автоматизированных системах. – 2015. – № 18. – С. 582-590.
8. Суперанская, А.В. Общая терминология: Вопросы теории. Аббревиация в терминологии / А.В. Суперанская, Н.В. Подольская, Н.В. Васильева. – Изд. 6-е. – М.: Книжный дом «ЛИБРОКОМ», 2012. – 248 с.
9. Нургалеева, Т.Г. Аббревиация как средство экспрессивного словообразования: автореф. дис. канд. филол. наук, спец. 10.02.04 «Германские языки» / Т. Г. Нургалеева. — М.: Наука, 2010. — 240 с.
10. Земская, Е.А. Современный русский язык. Словообразование: учеб. Пособие. 3-е изд., испр. и доб. – М.: Наука, 2011.
11. Jenkins K. Deciphering Journal Abbreviations with JAbbr // Code4Lib Journal. – 2009. – № 7. [Электронный ресурс] URL:<https://journal.code4lib.org/articles/1758> (Дата обращения: 09.11.2021)
12. Mikolov T. Efficient Estimation of Word Representations in Vector Space / T. Mikolov, K. Chen, G. Corrado, J. Dean // arXiv.org. — 2013. [Электронный ресурс] URL:<http://arxiv.org/pdf/1301.3781v3.pdf> (Дата обращения: 10.11.2021)
13. Mikolov T. Distributed Representations of Words and Phrases and their Compositionality / T. Mikolov, I. Sutskever, K. Chen, G. Corrado, J. Dean // Advances in Neural Information Processing Systems. – 2013. – P. 3111-3119.

14. Blei, D.M. Latent Dirichlet Allocation / D.M. Blei, A.Y. Ng, M.I. Jordan // Journal of Machine Learning Research. – 2003. – № 3. – P. 993- 1022.
15. Heinrich G. Parameter estimation for text analysis. – 2004. [Электронный ресурс] URL:<http://citeseerx.ist.psu.edu/view-doc/summary?doi=10.1.1.216.695> (Дата обращения: 10.11.2021)
16. Автоматизированное формирование перечня аббревиатур (сокращений) / А.А. Чумичкин, М.В. Рутц, Г.И. Трифонов // Свидетельство о регистрации программы для ЭВМ RU 2018663069, 19.10.2018. Заявка № 2018660897 от 04.10.2018.
17. Программа для извлечения и анализа терминологических структур смежных предметных областей / Д.А. Губанов // Свидетельство о регистрации программы для ЭВМ RU 2019665358, 22.11.2019. Заявка № 2018664640 от 18.11.2019.
18. Алексеев, Д.И. Сокращённые слова в русском языке. – Саратов: Изд-во Саратовского ун-та, 1979. – 328 с.
19. Виноградова, В.В. Русская грамматика: научные труды. В 2 т. Т. 1 – М.: Российская академия наук, 2005. — 784 с.
20. Ахманова, О.С. Словарь лингвистических терминов. – М.: Едито-риа УРСС, 2004. – 576 с.